딥러닝 #02

Keras 활용

문자열 입력 부분은 모두 함수로 대체가 가능

12

13

14

15)

optimizer="adam",

metrics=["accuracy"]

loss="categorical crossentropy",

- tf.keras.activations
- tf.keras.optimizers
- tf.keras.losses
- tf.keras.metrics


문자열 입력 부분은 모두 함수로 대체가 가능

- tf.keras.activations
- tf.keras.optimizers
- tf.keras.losses
- tf.keras.metrics

```
1 tf.keras.backend.clear session()
3 # 모델 생성 or 선택
4 X = tf.keras.layers.Input(shape=(784, ))
5 H = tf.keras.layers.Dense(128, activation=tf.keras.activations.relu)(X)
6 H = tf.keras.layers.Dense(128, activation=tf.keras.activations.relu)(H)
7 H = tf.keras.layers.Dense(128, activation=tf.keras.activations.relu)(H)
8 Y = tf.keras.layers.Dense(10, activation=tf.keras.activations.softmax)(H)
10 model = tf.keras.models.Model(X, Y)
11 model.compile(
      optimizer=tf.keras.optimizers.Adam(0.001),
      loss=tf.keras.losses.categorical crossentropy,
      metrics=[tf.keras.metrics.categorical accuracy]
15)
```

history

- 학습 진행 log 확인 가능
- loss와 metrics으로 지정된 값이 로깅된다.



```
1 result = model.fit(x train, y train,
                     epochs=10, batch size=128,
                     validation split=0.2)
4 model.evaluate(x test, y test)
1 import matplotlib.pyplot as plt
3 plt.plot(result.history['loss'])
4 plt.plot(result.history['val loss'])
5 plt.legend(['loss', 'val loss'])
```

Custom Loss / Metrics

- 직접 함수를 작성하여 적용
- y_true, y_pred 파라미터를 받는다.

```
17 model.compile(
18    loss=my_entropy,
19    optimizer=tf.keras.optimizers.Adam(0.001),
20    metrics=[my_accuracy]
21 )
```

```
1 def my_entropy(y_true, y_pred):
2    loss = tf.keras.backend.binary_crossentropy(y_true, y_pred)
3    return tf.reduce_mean(loss, axis=-1)
4
5 def my_accuracy(y_true, y_pred):
6    # tf.print(y_true, y_pred > 0.5)
7    equals = tf.math.equal(y_true, tf.cast(y_pred > 0.5, tf.float32))
8    return tf.reduce_mean(tf.cast(equals, tf.float32))
```

Model Save & Load

방법 1. 가중치와 모델을 한꺼번에 저장했다가 꺼내는 방법

```
1 model.save('model.h5', include_optimizer=True)
1 model = tf.keras.models.load_model('my_model.h5')
```


방법 2. 가중치와 모델을 따로 저장했다가 꺼내는 방법

```
1 model.save_weights('model_weights.h5')
2 with open('model.json', 'w') as f:
3    f.write(model.to_json())
```

```
1 with open('model.json', 'r') as f:
2   model = tf.keras.models.model_from_json(f.read())
3 model.load_weights('model_weights.h5')
```

Early Stopping

• overfitting이 발생하면 멈추고 멈추기 전 최적의 모델을 적용한다.



```
1 es = tf.keras.callbacks.EarlyStopping(
      monitor = 'val loss',
      min delta = 0, # 개선되고 있다고 판단하기 위한 최소 변화량
      patience = 10, # 개선 없는 epoch 얼마나 기달려 줄거야?
      verbose = 1
 6)
 8 # 학습
 9 result = model.fit(
10
      x train, y train,
      epochs=20000, batch size=128, validation split=0.2,
12
      callbacks=[es]
13)
14
15 model.evaluate(x test, y test)
```


Optimizer

Gradient Descent (경사하강법)

함수의 기울기(경사)를 구하여 함수의 극값에 이를 때까지 기울기가 낮은 쪽으로 반복하여 이동하는 방법.

• SGD

$$W(t+1) = W(t) - \alpha \frac{\partial}{\partial w} Cost(w)$$




Momentum (관성)

이전에 이동했던 방향을 기억해서 다음 이동의 방향에 반영.

NAG

$$V(t) = m * V(t - 1) - \alpha \frac{\partial}{\partial w} Cost(w)$$
$$W(t + 1) = W(t) + V(t)$$



Adagrad (Adaptive Gradient)

많이 이동한 변수(w)는 최적값에 근접했을 것이라는 가정하에, 많이 이동한 변수(w)를 기억해서 다음 이동의 거리를 줄인다.

• RMSprop

$$G(t) = G(t-1) + \left(\frac{\partial}{\partial w(t)}Cost(w(t))\right)^{2}$$

$$= \sum_{i=0}^{t} \left(\frac{\partial}{\partial w(i)}Cost(w(i))\right)^{2}$$

$$W(t+1) = W(t) - \alpha * \frac{1}{\sqrt{G(t) + \epsilon}} * \frac{\partial}{\partial w(i)}Cost(w(i))$$

Adam (RMSprop + Momentum)


$$M(t) = \beta_1 M(t-1) + (1-\beta_1) \frac{\partial}{\partial w(t)} Cost(w(t))$$

$$V(t) = \beta_2 V(t-1) + (1-\beta_2) \left(\frac{\partial}{\partial w(i)} Cost(w(i))\right)^2$$

$$\widehat{M}(t) = \frac{M(t)}{1-\beta_1^t} \quad \widehat{V}(t) = \frac{V(t)}{1-\beta_2^t}$$

$$W(t+1) = W(t) - \alpha * \frac{\widehat{M}(t)}{\sqrt{\widehat{V}(t) + \epsilon}}$$


산 내려오는 작은 오솔길 잘찿기(Optimizer)의 발달 계보





출처: 하용호, 자습해도 모르겠던 딥러닝, 머리속에 인스톨 시켜드립니다

Chain Rule & Back Propagation

- 학습 = 'Cost'를 줄이는 방향으로 가중치를 조절한다.
- 가중치를 a만큼 변화시키면 Error는 어떻게 변화할까 → 미분을 해보면 된다.
- 미분이 복잡해. 함수 안에 함수가 있고 그 안에 또… → Chain Rule을 쓰면 된다!








Activation


Activation (활성화 함수)

Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$




Leaky ReLU $\max(0.1x, x)$



tanh

tanh(x)





Maxout

 $\max(w_1^T x + b_1, w_2^T x + b_2)$

ReLU

 $\max(0,x)$







vanishing gradient 이유

아래는 sigmoid, tanh의 미분 함수


0.25/0.5 보다 작은 값이 중첩되어 곱해지면서 미분값이 0에 수렴하게 된다.



최근의 좋은 활성화 함수



 $f(x) = x \cdot \operatorname{sigmoid}(\beta x)$



$$\mathrm{GELU}(x) = x \cdot rac{1}{2} \Big[1 + \mathrm{erf}(x/\sqrt{2}) \Big]$$

Loss Function

MSE (Mean Square Error)

$$loss_i = (y_i - \hat{y_i})^2$$

Cross Entropy

$$error = -\sum_{i}^{n} y_i \log \hat{y}_i \quad loss_i = -(y_i log(\hat{y}_i) + (1 - y_i) log(1 - \hat{y}_i))$$


activation function – softmax

$$softmax(x_i) = \frac{e^{x_i}}{e^{x_1} + e^{x_2} + \dots + e^{x_n}} = \frac{e^{x_i}}{\sum_{c}^{n} e^{x_c}}$$


Overfitting

훈련 데이터에 특화된 학습을 하게 되어 새로운 데이터에 대한 예측이 오히려 나빠지거나 학습의 효과가 나타나지 않는 상태

(a)



- Dropout / Ensemble
- Batch Normalization
- L1, L2 Regularization
- Data Augmentation




(c)

(b)


Dropout

- 지정된 확률의 개수만큼 노드를 랜덤하게
 제외하고 학습을 진행.
- 완성된 모델에서는 모든 노드를 사용.
- 효과
 - o 오버피팅 방지
 - 성능 향상
 - ㅇ 앙상블 효과


학습이 된다면 최대한 높게 줄수록 좋다. 데이터가 충분하면 0.4 ~ 0.6



(a) Standard Neural Net



(b) After applying dropout.




Training time


Batch Normalization

- Layer 사이에 중간 결과 데이터들을 표준정규화하는 계층
 - o 학습 단계에서는 batch 단위로 정규화하고
 - \circ 모델 적용시의 σ, μ 는 사용하던 값들의 이동평균값을 이용한다.
- Internal Covariant Shift 문제를 해결한다.
- 무조건 쓴다고 가정하자.


$$BN(\mathbf{x}_i) = \gamma \odot (\frac{\mathbf{x}_i - \mu_B}{\sigma_B}) + \beta,$$




Batch Normalization



L1, L2 Regularization



$$\beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4$$



$$\min_{\beta} \sum_{i=1}^{\infty} (y_i - \hat{y}_i)^2 + 5000\beta_3^2 + 5000\beta_4^2$$

L1, L2 Regularization

- L1 (lasso)
 - 중요도가 낮은 가중치부터 0이 됨.
 - 변수 선택의 효과
- L2 (ridge)
 - o 아주 큰 가중치에 페널티 부여
 - 가중치들이 전체적으로 평평해짐

L1 Regularization

Cost =
$$\sum_{i=0}^{N} (y_i - \sum_{j=0}^{M} x_{ij} W_j)^2 + \lambda \sum_{j=0}^{M} |W_j|$$

L2 Regularization

Cost =
$$\sum_{i=0}^{N} (y_i - \sum_{j=0}^{M} x_{ij} W_j)^2 + \lambda \sum_{j=0}^{M} W_j^2$$
Loss function Regularization Term

Use Local Image

tqdm 패키지

100%

1 !pip install tqdm

• loop에서 progress bar를 이용해 loop의 진행상황을 표시해 줍니다.


```
Requirement already satisfied: tqdm in /usr/local/lib/python3.6/dist-packages (4.41.1)

1 import tqdm
2 import time
3 |
4 for i in tqdm.notebook.tqdm(range(10000)):
5 time.sleep(0.001)
```

10000/10000 [00:11<00:00, 889.32it/s]

notMNIST datasets

- http://yaroslavvb.com/upload/notMNIST/notMNIST_large.tar.gz
- 1 !wget http://yaroslavvb.com/upload/notMNIST/notMNIST_large.tar.gz
- 2 !tar -xvzf notMNIST_large.tar.gz



압축 하기

□ 사용법

1 | \$ tar -cvzf [압축된 파일 이름] [압축할 파일이나 폴더명]

압축 풀기

□ 사용법

1 \$ tar -xvzf [압축 해제할 압축 아카이브 이름]

notMNIST datasets

• 파일목록 선택

```
1 import random
 2 import tqdm
 3 import glob
 5 # 파일목록 가져오기
 6 paths = glob.glob('./notMNIST large/*/*.png')
 7 print(len(paths))
 8 print(paths[:10])
 9
10 # 파일 목록 순서 섞어서
11 random.shuffle(paths)
12 # 상위 60000개의 데이터만 사용
13 paths = paths[:60000]
```

notMNIST datasets

• 이미지 로딩하기

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 # 이미지 데이터셋 로드
5 x train, y train = [], []
 6 for p in tqdm.notebook.tqdm(paths):
      x train.append(plt.imread(paths[0]))
      y train.append(p.split('/')[2])
 9
10 x train = np.array(x train)
11 y_train = np.array(y_train)
12 print(x train.shape, y train.shape)
```

Data

tf.data.Dataset

• data셋을 미리 구성해주는 도구

```
1 train ds = tf.data.Dataset.from tensor slices((x train[:50000], y train[:50000]))
 2 train ds = train ds.shuffle(1000).batch(128)
 3 valid ds = tf.data.Dataset.from tensor slices((x train[50000:], y train[50000:]))
 4 valid ds = valid ds.batch(128)
 1 train x, train y = next(iter(train ds))
 2 print(train x.shape, train y.shape)
 3 valid x, valid y = next(iter(valid ds))
 4 print(valid x.shape, valid y.shape)
(128, 28, 28, 1) (128,)
(128, 28, 28, 1) (128,)
```

<u>ImageDataGenerator</u>

• 기존 이미지를 변형해서 새로운 이미지를 생성해주는 도구

```
1 datagen = tf.keras.preprocessing.image.ImageDataGenerator(
      width shift range=0.2,
      height shift range=0.2,
      horizontal flip=True
 5)
 6 train ds = datagen.flow(x train[:50000], y train[:50000], batch size=128)
 8 valid ds = tf.data.Dataset.from tensor slices((x train[50000:], y train[50000:]))
 9 valid ds = valid ds.batch(128)
 1 train x, train y = next(iter(train ds))
 2 print(train x.shape, train y.shape)
 3 valid x, valid y = next(iter(valid ds))
 4 print(valid x.shape, valid y.shape)
(128, 28, 28, 1) (128,)
(128, 28, 28, 1) (128,)
```